

Машинное обучение. Линейные модели

Алексей Колесов

Белорусский государственный университет

11 сентября 2019 г.

Линейные модели

- часто используются
- простой алгоритм обучения
- интерпретируемы

Линейные модели

Класс аффинных функций:

$$H_d = \{h_{w,b} : w \in \mathbb{R}^d, b \in \mathbb{R}\}$$

где

$$h_{w,b}(x) = \langle w, x \rangle + b = \left(\sum_{i=1}^d w_i x_i \right) + b$$

или в другой нотации:

$$H_d = \{x \mapsto \langle w, x \rangle + b : w \in \mathbb{R}^d, b \in \mathbb{R}\}$$

Линейные модели

Семейства гипотез обычно строятся как композиции функции $\phi : \mathbb{R} \rightarrow Y$ и H_d

- для бинарной классификации: $\phi = \text{sign}$
- для регрессии: $\phi = \text{id}$

Однородные линейные функции

- $h_w(x) = \langle w, x \rangle$ называется однородной (гомогенной) линейной функцией
- зачастую b (bias) вносят в w , и добавляют во все x_i константный признак (1)

$$w' = (b, w_1, \dots, w_d) \in \mathbb{R}^{d+1}$$

$$x' = (1, x_1, \dots, x_d) \in \mathbb{R}^{d+1}$$

тогда

$$h_{w,b}(x) = \langle w, x \rangle + b = h_{w'}(x) = \langle w', x' \rangle$$


Содержание

- 1 Полупространства (halfspaces)
 - Линейное программирование
 - Алгоритм Perceptron
- 2 Линейная регрессия
 - Метод наименьших квадратов (МНК)
 - Многомерная линейная регрессия
 - Проблема мультиколлинеарности
 - Гребневая регрессия
- 3 Логистическая регрессия
- 4 Итоги

Класс гипотез: полупространства

Решаем задачу бинарной классификации: $X = \mathbb{R}^d$, $Y = \{-1, 1\}$

$$HS_d = \text{sign} \circ H_d = \{x \mapsto \text{sign}(h_{w,b}(x)) : h_{w,b} \in H_d\}$$



Гарантии

- изучаемый с помощью ERM-парадигмы, если размер выборки $\Omega\left(\frac{d + \log(1/\delta)}{\epsilon}\right) \Rightarrow$ хотим алгоритм для нахождения ERM-гипотезы
- агностический случай — вычислительно сложен¹ \Rightarrow обычно заменяют функцию потерь
- рассмотрим алгоритмы в случае предположения о реализуемости (**разделимая** выборка)

¹Ben-David & Simon 2001

Задача линейного программирования

Задача линейного программирования — задача максимизации линейной функции при линейных ограничениях:

$$\begin{aligned} \max_{w \in \mathbb{R}^d} \langle u, w \rangle \\ Aw \geq v \end{aligned}$$

- $w \in \mathbb{R}^d$ — искомый вектор переменных
- $A \in \mathbb{R}^{m \times d}$
- $v, u \in \mathbb{R}^d$

Задачи эффективно разрешимы (за полиномиальную от m , d и длины чисел сложность)

Сведение к ЛП: постановка

Цель: свести нахождение ERM-гипотезы для класса HS_d в случае разделимой выборки к задаче линейного программирования

Дано:

$$S = \{(x_i, y_i)\}_{i=1}^m \text{ — выборка}$$

Хотим: найти w (рассмотрим однородный случай), такой что:

$$\text{sign}(\langle w, x_i \rangle) = y_i, \forall i = 1, \dots, m$$

Сведение к ЛП

Ищем w , такой что:

$$\text{sign}(\langle w, x_i \rangle) = y_i, \forall i = 1, \dots, m$$

По-другому:

$$y_i \langle w, x_i \rangle > 0, \forall i = 1, \dots, m$$

Обозначим за w^* вектор, который удовлетворяет предыдущему свойству (такой есть, так как выборка разделима)

Сведение к ЛП

Знаем, что есть w^* , такой что:

$$y_i \langle w^*, x_i \rangle > 0, \forall i = 1, \dots, m$$

Пусть:

$$\gamma = \min_i (y_i \langle w^*, x_i \rangle)$$
$$\bar{w} = \frac{w^*}{\gamma}$$

Имеем:

$$y_i \langle \bar{w}, x_i \rangle = \frac{1}{\gamma} \langle w^*, x_i \rangle \geq 1, \forall i = 1, \dots, m$$

Сведение к ЛП: итог

- доказали, что если выборка разделима, то $\exists w \in \mathbb{R}^d$, такой что $y_i \langle w, x_i \rangle \geq 1 \ \forall i = 1, \dots, m$
- w , удовлетворяющий этим условиям, задаёт ERM-гипотезу в классе линейных моделей
- можно найти с помощью задачи ЛП

Сведение к ЛП: итог

- доказали, что если выборка разделима, то $\exists w \in \mathbb{R}^d$, такой что $y_i \langle w, x_i \rangle \geq 1 \ \forall i = 1, \dots, m$
- w , удовлетворяющий этим условиям, задаёт ERM-гипотезу в классе линейных моделей
- можно найти с помощью задачи ЛП
 - A — матрица, в которой каждая строка — объект x_i , умноженный на y_i

Сведение к ЛП: итог

- доказали, что если выборка разделима, то $\exists w \in \mathbb{R}^d$, такой что $y_i \langle w, x_i \rangle \geq 1 \ \forall i = 1, \dots, m$
- w , удовлетворяющий этим условиям, задаёт ERM-гипотезу в классе линейных моделей
- можно найти с помощью задачи ЛП
 - A — матрица, в которой каждая строка — объект x_i , умноженный на y_i
 - v — вектор из m единиц


Сведение к ЛП: итог

- доказали, что если выборка разделима, то $\exists w \in \mathbb{R}^d$, такой что $y_i \langle w, x_i \rangle \geq 1 \ \forall i = 1, \dots, m$
- w , удовлетворяющий этим условиям, задаёт ERM-гипотезу в классе линейных моделей
- можно найти с помощью задачи ЛП
 - A — матрица, в которой каждая строка — объект x_i , умноженный на y_i
 - v — вектор из m единиц
 - u — произвольный (например, нулевой) вектор

Алгоритм Perceptron: общее описание

- итеративный алгоритм, предложенный Розенблатом в 1958-м году
- начинается с $w^{(1)}$ — нулевого вектора
- на каждом шаге находит неправильно классифицируемый объект и «подправляет» w
- останавливается, когда найдена ERM-гипотеза

Mark I Perceptron



Алгоритм Perceptron: шаг

Пусть на шаге t имеем $w^{(t)}$ и объект x_i , который классифицируется неверно:

$$\text{sign}(\langle w^{(t)}, x_i \rangle) \neq y_i$$

Положим:

$$w^{(t+1)} = w^{(t)} + y_i x_i$$

Алгоритм Perceptron: обоснование шага

Шаг алгоритма:

$$w^{(t+1)} = w^{(t)} + y_i x_i, \text{ при чём } \text{sign}(\langle w^{(t)}, x_i \rangle) \neq y_i$$

Мы хотим, чтоб $\forall i = 1, \dots, m$:

$$y_i \langle w, x_i \rangle > 0$$

Распишем:

$$y_i \langle w^{(t+1)}, x_i \rangle = y_i \langle w^{(t)} + y_i x_i, x_i \rangle = y_i \langle w^{(t)}, x_i \rangle + \|x_i\|^2$$

Алгоритм Perceptron

Алгоритм 1 Batch perceptron

Вход: Разделимая тренировочная выборка $S = \{(x_1, y_1), \dots, (x_m, y_m)\}$

Выход: w , такой что $y_i \langle w, x_i \rangle > 0 \ \forall i = 1, \dots, m$

```
1:  $w^{(1)} = (0, \dots, 0)$ 
2: for  $t = 1, 2, \dots$  do
3:   if  $\exists i$ , т.ч.  $y_i \langle w^{(t)}, x_i \rangle \leq 0$  then
4:      $w^{(t+1)} = w^{(t)} + y_i x_i$ 
5:   else
6:     return  $w^{(t)}$ 
7:   end if
8: end for
```

Теорема о сходимости алгоритма Perceptron

Теорема о сходимости алгоритма Perceptron

Пусть $S = \{(x_1, y_1), \dots, (x_m, y_m)\}$ — **линейно разделимая** выборка. Обозначим $B = \min\{\|w\| : y_i \langle w, x_i \rangle \geq 1 \ \forall i \in [m]\}$, $R = \max_i \|x_i\|$. Тогда алгоритм 1 завершает свою работу не более, чем через $(RB)^2$ итераций, и итоговый вектор w удовлетворяет условию $y_i \langle w, x_i \rangle > 0$ для всех объектов выборки.

Доказательство теоремы

- докажем, что если алгоритм остановился на итерации T , то $T \leq (RB)^2$
- пусть w^* — вектор, доставляющий минимум в определении $B = \min\{\|w\| : y_i \langle w, x_i \rangle \geq 1 \ \forall i \in [m]\}$
- докажем,

$$\frac{\langle w^*, w^{(t+1)} \rangle}{\|w^*\| \|w^{(t+1)}\|} \geq \frac{\sqrt{t}}{RB}$$

Доказательство теоремы

Хотим:

$$\frac{\langle w^*, w^{(t+1)} \rangle}{\|w^*\| \|w^{(t+1)}\|} \geq \frac{\sqrt{t}}{RB}$$

Имеем:

- $\|w^*\| = B$

Докажем:

- $\langle w^*, w^{(t+1)} \rangle \geq t$
- $\|w^{(t+1)}\| \leq \sqrt{t}R$

Доказательство теоремы

Хотим:

$$\langle w^*, w^{(t+1)} \rangle \geq t$$

Имеем: w^* — вектор, доставляющий минимум в определении $B = \min\{\|w\| : y_i \langle w, x_i \rangle \geq 1 \ \forall i \in [m]\}$

Доказательство:

- $w^{(1)} = (0, \dots, 0) \Rightarrow \langle w^*, w^{(t+1)} \rangle = 0 \geq 0$

- пусть на итерации t мы выбрали (x_i, y_i) :

$$\begin{aligned}\langle w^*, w^{(t+1)} \rangle - \langle w^*, w^{(t)} \rangle &= \langle w^*, w^{(t+1)} - w^{(t)} \rangle \\ \langle w^*, w^{(t+1)} - w^{(t)} \rangle &= \langle w^*, y_i x_i \rangle = y_i \langle w^*, x_i \rangle \geq 1\end{aligned}$$

Доказательство теоремы

Хотим:

$$\|w^{(t+1)}\| \leq \sqrt{t}R$$

Имеем:

$$R = \max_i \|x_i\|$$

Доказательство:

$$\begin{aligned}\|w^{(t+1)}\|^2 &= \|w^{(t)} + y_i x_i\|^2 = \|w^{(t)}\|^2 + 2y_i \langle w^{(t)}, x_i \rangle + y_i^2 \|x_i\|^2 \\ 2y_i \langle w^{(t)}, x_i \rangle &< 0 \text{ (по построению алгоритма)} \\ \|w^{(t+1)}\|^2 &\leq \|w^{(t)}\|^2 + R^2 \\ \|w^{(1)}\|^2 = 0 &\Rightarrow \|w^{(t+1)}\|^2 \leq tR^2\end{aligned}$$

Доказательство алгоритма

Имеем:

- $\langle w^*, w^{(t+1)} \rangle \geq t$
- $\|w^{(t+1)}\| \leq \sqrt{t}R$
- $\|w^*\| = B$

Таким образом:

$$\frac{\langle w^*, w^{(t+1)} \rangle}{\|w^*\| \|w^{(t+1)}\|} \geq \frac{\sqrt{t}}{RB}$$

Алгоритм 1 завершает свою работу не более, чем за $(RB)^2$ итераций

- алгоритм прост в реализации
- гарантировано находит решение
- B может быть экспоненциально большим относительно d
- на практике B невелико

Итоги

- в случае разделимой выборки решать задачу просто, в случае неразделимой — сложно
- что делать, если выборка неразделима?
- решений несколько, какое выбрать?

Содержание

- 1 Полупространства (halfspaces)
 - Линейное программирование
 - Алгоритм Perceptron
- 2 Линейная регрессия
 - Метод наименьших квадратов (МНК)
 - Многомерная линейная регрессия
 - Проблема мультиколлинеарности
 - Гребневая регрессия
- 3 Логистическая регрессия
- 4 Итоги

Задачи восстановления регрессии

- задачи машинного обучения, где $Y = \mathbb{R}$ традиционно называют **задачами восстановления регрессии**²
- функция потерь должна отличаться от 0-1 loss
- зачастую разумным выбором является квадратичная функция потерь $L_S(h) = \sum_{i=1}^m (h(x_i) - y_i)^2$
- обучение с такой функцией потерь называется **метод наименьших квадратов (least squares)**

²Francis Galton «Regression towards mediocrity in heredity stature»

Метод наименьших квадратов

- Рассмотрим $H = \{h_\alpha(x)\}$, где $\alpha \in \mathbb{R}^d$ — **параметры модели**
- $RSS_S(h) = \sum_{i=1}^m w_i (h_\alpha(x_i) - y_i)^2$, где w_i — степень важности объекта; такая функция потерь называется **остаточная сумма квадратов (residual sum of squares)**
- $MSE_S(h) = \frac{1}{m} \sum_{i=1}^m (h_\alpha(x_i) - y_i)^2$ — **mean square error**
- обучение по правилу $A(S) = h_{\alpha^*}$, где $\alpha^* = \operatorname{argmin}_{\alpha} RSS_S(h_\alpha)$ называется **методом наименьших квадратов (least squares)**

МНК: минимизация

Хотим минимизировать $\sum_{i=1}^m w_i (h_{\alpha}(x_i) - y_i)^2$.

Если h достаточно гладкая, то можно решить:

$$\frac{\partial \text{RSS}_S}{\partial \alpha} = 2 \sum_{i=1}^m w_i (h_{\alpha}(x_i) - y_i) \frac{\partial h_{\alpha}}{\partial \alpha}(x_i) = 0$$

Метод максимального правдоподобия

Метод максимального правдоподобия (Maximum likelihood estimation)

Пусть дана выборка (x_1, \dots, x_m) из распределения вероятности P_α , где α — неизвестный вектор параметров. Тогда оценка $\alpha^* = \underset{\alpha}{\operatorname{argmax}} P((x_1, \dots, x_m) | \alpha)$ называется **оценкой максимального правдоподобия**

- состоятельная
- асимптотически эффективная
- асимптотически нормальная

МНК = ММП

Теорема о ММП оценке в случае гауссовского шума

Пусть разметочная функция f имеет вид:

$$f(x_i) = h_{\alpha}(x_i) + \epsilon_i$$

где ϵ_i — независимые нормальные случайные величины с нулевым средним и дисперсией σ_i^2 . Тогда МНК-решение и ММП-оценка для α совпадает, в случае, если веса объектов w_i обратно пропорциональны дисперсии шума σ_i^2

Доказательство

Запишем функцию правдоподобия:

$$P(\epsilon_1, \dots, \epsilon_m | \alpha) = \prod_{i=1}^m \frac{1}{\sigma_i \sqrt{2\pi}} \exp \left(-\frac{1}{2\sigma_i^2} (h_\alpha(x_i) - y_i)^2 \right)$$

Прологарифмируем:

$$\ln P(\epsilon_1, \dots, \epsilon_m | \alpha) = \text{const}(a) - \frac{1}{2} \sum_{i=1}^m \frac{1}{\sigma_i^2} (h_\alpha(x_i) - y_i)^2$$

Итоги

- w_i можно рассматривать как меру точности измерения признака i
- если предположение теоремы выполнено, то МНК-оценка имеет высокое качество
- если не выполнено, то сколько угодно плохое

Многомерная линейная регрессия

- пусть $X = \mathbb{R}^d$ и H — линейные функции: $h_w(x) = \langle w, x \rangle$
- $\text{MSE}_S(h) = \frac{1}{m} \sum_{i=1}^m (\langle w, x_i \rangle - y_i)^2$
- МНК оценка выражается из уравнения:
$$\frac{2}{m} \sum_{i=1}^m (\langle w, x_i \rangle - y_i) x_i = 0$$

Или в матричном виде

Матричная постановка задачи

Имеем: $\frac{2}{m} \sum_{i=1}^m (\langle w, x_i \rangle - y_i) x_i = 0$

Положим: $A = \left(\sum_{i=1}^m x_i x_i^T \right)$, $b = \sum_{i=1}^m y_i x_i$, решаем $Aw = b$

$$A = XX^T = \begin{pmatrix} \vdots & & \vdots \\ x_1 & \dots & x_m \\ \vdots & & \vdots \end{pmatrix} \begin{pmatrix} \vdots & & \vdots \\ x_1 & \dots & x_m \\ \vdots & & \vdots \end{pmatrix}^T$$
$$b = Xy = \begin{pmatrix} \vdots & & \vdots \\ x_1 & \dots & x_m \\ \vdots & & \vdots \end{pmatrix} \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$$

Полиномиальная регрессия

- пусть $X = \mathbb{R}$, положим $x'_i = (1, x_i, x_i^2, \dots, x_i^d)$
- полученная модель называется моделью **полиномиальной регрессии**
- X^T в этом случае называется

Полиномиальная регрессия

- пусть $X = \mathbb{R}$, положим $x'_i = (1, x_i, x_i^2, \dots, x_i^d)$
- полученная модель называется моделью **полиномиальной регрессии**
- X^T в этом случае называется матрицей Вандермонда

Криволинейная регрессия

- пусть $X = \mathbb{R}^d$, т.е. $x_i = (x_i^{(1)}, \dots, x_i^{(d)})$
- пусть $X' = \mathbb{R}^{d'}$, $x'_i = (\phi_1(x_i), \dots, \phi_{d'}(x_i))$
- линейная модель на пространстве X' называется моделью **криволинейной регрессии**
- X'^T — обобщённая матрица Вандермонда

Нормальная система уравнений

Имеем:

$$A = XX^T = \begin{pmatrix} \vdots & & \vdots \\ x_1 & \dots & x_m \\ \vdots & & \vdots \end{pmatrix} \begin{pmatrix} \vdots & & \vdots \\ x_1 & \dots & x_m \\ \vdots & & \vdots \end{pmatrix}^T$$
$$b = Xy = \begin{pmatrix} \vdots & & \vdots \\ x_1 & \dots & x_m \\ \vdots & & \vdots \end{pmatrix} \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$$

Хотим решить задачу:

$$XX^T w = Xy$$

Нормальная система уравнений

Хотим решить задачу:

$$XX^T w = Xy$$


Если XX^T невырождена, то: $w = (XX^T)^{-1}Xy$

Матрица $(XX^T)^{-1}X$ называется **псевдообратной** для прямоугольной матрицы X^T .

$$\text{MSE}_S(h_w) = \|X(XX^T)^{-1}Xy - y\|^2 = \|P_X y - y\|^2$$

где, $P_X = X^T(XX^T)^{-1}X$ — проекционная матрица на пространство строк матрицы X

Геометрическая интерпретация



Сингулярное разложение

SVD-разложение (singular value decomposition)

Произвольную матрицу X размера $d \times m$ можно разложить в произведение трёх матриц:

$$X = UDV^T$$

- $U = (u_1, \dots, u_d)$ имеет размеры $d \times d$ ($U^T U = I$), столбцы — собственные векторы XX^T
- D — диагональная размера $d \times m$, на главной диагонали корни собственных чисел XX^T , $X^T X$; число ненулевых таких значений равно рангу X , $X^T X$, XX^T (в случае \mathbb{R})
- $V = (v_1, \dots, v_m)$ имеет размер $m \times m$, ($V^T V = I$); столбцы — собственные векторы $X^T X$.

Решение МНК через SVD

Решаем:

$$XX^T w = Xy$$

Имеем:

$$w = (XX^T)^{-1}Xy$$
$$(X^T)^+ = (XX^T)^{-1}X — \text{псевдообратная для } X^T$$

SVD для X^T

$$X = UDV^T \Rightarrow X^T = VD^T U^T$$

Значит:

$$(X^T)^+ = (UDV^T VD^T U^T)^{-1}UDV^T$$

Замечание про D

$$D = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 \\ 0 & 0 & 3 & 0 & 0 \end{pmatrix} \quad D^T = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad DD^T = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 9 \end{pmatrix}$$
$$D^+ = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1/2 & 0 \\ 0 & 0 & 1/3 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad (D^T)^+ = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/3 & 0 & 0 \end{pmatrix}$$

Псевдообратная матрица через SVD

$$(X^T)^+ = (UD\mathbf{V}^T\mathbf{V}D^T U^T)^{-1}UD\mathbf{V}^T \quad (1)$$

$$(X^T)^+ = (U(DD^T)U^T)^{-1}UD\mathbf{V}^T \quad (2)$$

$$(X^T)^+ = (\mathbf{U}^T)^{-1}(DD^T)^{-1}\mathbf{U}^{-1}UD\mathbf{V}^T \quad (3)$$

$$(X^T)^+ = U(DD^T)^{-1}\mathbf{U}^T UD\mathbf{V}^T \quad (4)$$

$$(X^T)^+ = U(\mathbf{D}\mathbf{D}^T)^{-1}\mathbf{D}\mathbf{V}^T \quad (5)$$

$$(X^T)^+ = U(\mathbf{D}^T)^+ \mathbf{V}^T \quad (6)$$

МНК-решение через SVD

Решение, через SVD:

$$w = (XX^T)^{-1}Xy = U(D^T)^+V^Ty = \sum_{i=1}^d \frac{1}{\sqrt{\lambda_i}} u_i(v_i^Ty)$$

u_i — столбцы матрицы U v_i^T — строки матрицы V^T

Проекционный оператор через SVD:

$$P_X y = X^T(XX^T)^{-1}Xy = VD^T U^T U(D^T)^+V^T = \sum_{i=1}^d v_i(v_i^Ty)$$

Норма вектора:

$$\|w\|^2 = \|(D^T)^+V^Ty\|^2 = \sum_{i=1}^d \frac{1}{\lambda_i} (v_i^Ty)^2$$

Стандартизация данных

- разные признаки в разных масштабах (единицах измерения)
- проводят **стандартизацию** данных: $f_i = (f_i - \bar{f}_i) / \sigma_i$
- такое же преобразование при применении

Проблема мультиколлинеарности

- если XX^T неполного ранга, её нельзя обратить
- на практике, чаще ранг полный, но матрица близка к матрице неполного ранга — проблема мультиколлинеарности (матрица *плохо обусловлена*, *неполоного псевдоранга*)
- случается, если объекты сконцентрированы около пространства меньшей размерности, чем d
- малые собственные значения

Проблемы с мультиколлинеарностью

- повышается разброс коэффициентов (см. формулу для w)
- повышается неустойчивость решения
- понижается обобщающая способность алгоритма

Методы борьбы с проблемой

- регуляризация
- преобразование признаков
- отбор признаков

Гребневая регрессия (ridge regression)

Изменим функцию потерь:

$$L_S(h_w) = \frac{1}{m} \sum_{i=1}^m (\langle w, x_i \rangle - y_i)^2 + \tau \|w\|^2$$

Тогда решение:

$$w = (XX^T + \tau I)^{-1} Xy$$

Через SVD:

$$\|w\|^2 = \|(D^T)^+ V^T y\|^2 = \sum_{i=1}^d \frac{1}{\lambda_i + \tau} (v_i^T y)^2$$

Происходит сжатие весов (weight decay)

Выбор τ

- слишком большой и слишком маленький параметр τ — плохо
- вопрос: как выбирать
- ответ: см. следующие лекции
- ответ 2: пытаются выбрать τ так, что получить обусловленность матрицы в заранее заданном диапазоне

Лассо Тибширани

$$\begin{cases} L_S(h_w) = \frac{1}{m} \sum_{i=1}^m (\langle w, x_i \rangle - y_i)^2 \rightarrow \min \\ \sum_{i=1}^d |w_i| \leq \psi \end{cases}$$

- $w_i = w_i^+ - w_i^-$
- $w_i^+ \geq 0$
- $w_i^- \geq 0$
- $\sum_{i=1}^d w_i^+ + w_i^- \leq \psi$

Least absolute shrinkage and selection operator (LASSO)

Итоги

- МНК-оценка лучшая, если шумы гауссовы
- Метод хорошо изучен, допускает много обобщений
- Оценка неустойчива к шумным выбросам
- Для борьбы с мультиколлинеарностью зачастую используют ridge regression, иногда LASSO

Содержание

- 1 Полупространства (halfspaces)
 - Линейное программирование
 - Алгоритм Perceptron
- 2 Линейная регрессия
 - Метод наименьших квадратов (МНК)
 - Многомерная линейная регрессия
 - Проблема мультиколлинеарности
 - Гребневая регрессия
- 3 Логистическая регрессия
- 4 Итоги

Логистическая регрессия

- вернёмся к задаче классификации

- эмпирический риск:


$$L_S(h) = \frac{|\{i \in [m] : h(x_i) \neq y_i\}|}{m} = \frac{|\{i \in [m] : y_i \langle w, x_i \rangle < 0\}|}{m}$$

- классификация слишком жёсткая

- будем считать, что $\phi(x) = \sigma(x) = \frac{1}{1 + \exp(-x)}$, т.е.

$$H_d = \{x \mapsto \sigma(\langle w, x \rangle + b) : w \in \mathbb{R}^d, b \in \mathbb{R}\}$$

Сигмоидальная функция



$$\sigma(x) = \frac{1}{1 + \exp(-x)}$$

Экспоненциальные функции распределения

Экспоненциальные функции распределения

Плотность распределения $p(x)$, $x \in \mathbb{R}^d$ называется экспоненциальной, если:

$$p(x) = \exp \left(\theta^T x \cdot a(\delta) + b(\delta, \theta) + d(x, \delta) \right)$$

- $\theta \in \mathbb{R}^d$ — сдвиг
- δ — разброс
- a, b, d — произвольные числовые функции

Многие известные распределения экспоненциальны:
равномерное, пуассоновское, биномиальное

Нормальное тоже является с $\theta = \Sigma^{-1}\mu$, $\delta = \Sigma$

Оптимальный байесовский классификатор

Оптимальный байесовский классификатор

Классификатор:

$$f_D(x) = \operatorname{argmax}_y D(x, y) = \operatorname{argmax}_y P(y|x)$$

называется **оптимальным байесовским классификатором**

Обоснование логистической регрессии

Теорема об оптимальности логистической регрессии

Пусть

- среди признаков есть константа
- плотности правдоподобия классов $P(x|y)$ являются экспоненциальными с равными разбросами

Тогда

- байесовское правило линейно $a(x) = \text{sign}(\langle w, x \rangle)$
- $P(y|x) = \sigma(y\langle w, x \rangle)$

Доказательство

$$\frac{P(+1|x)}{P(-1|x)} = \frac{P(x|y=1)P(y=1)P(x)}{P(x|y=-1)P(y=-1)P(x)}$$

Распишем

$$\exp \left(\alpha(\delta)(\theta_+ - \theta_-)^T x + b(\delta, \theta_+) - b(\delta, \theta_-) + \ln \frac{P(y=1)}{P(y=-1)} \right)$$

А значит

$$\begin{aligned} \frac{P(+1|x)}{P(-1|x)} &= \exp(\langle w, x \rangle) \\ P(+1|x) &= \sigma(\langle w, x \rangle) \\ P(-1|x) &= \sigma(-\langle w, x \rangle) \end{aligned}$$

Решение для w

- как найти вектор w ?
- функция логарифма правдоподобия

$$L(w) = \sum_{i=1}^m \ln \sigma(y_i \langle wx_i \rangle) + C \rightarrow \max$$

- полученная функция выпуклая, мы научимся находить максимум подобных функций через несколько лекций

Итоги

- регрессия может помочь решить задачу классификации
- при определённых предположениях решение логистической регрессии ведёт себя оптимально
- даёт возможность вычислять вероятность классов
- позволяет решать задачу скоринга

Содержание

- 1 Полупространства (halfspaces)
 - Линейное программирование
 - Алгоритм Perceptron
- 2 Линейная регрессия
 - Метод наименьших квадратов (МНК)
 - Многомерная линейная регрессия
 - Проблема мультиколлинеарности
 - Гребневая регрессия
- 3 Логистическая регрессия
- 4 Итоги

Итоги

- рассмотрели семейство линейных моделей
- разобрали два ERM-алгоритма для нахождения линейной модели в случае разделимой выборки: сведение к задаче линейного программирования и алгоритм Perceptron
- рассмотрели задачу линейной регрессии и предложили методы для борьбы с проблемой мультиколлинеарности: гребневая регрессия и Лассо
- ввели понятие логистической регрессии

Литература

- Shai Shalev-Shwartz and Shai Ben-David — Understanding Machine Learning: From theory to algorithms (глава 9)
- К.В.Воронцов — Лекции по алгоритмам восстановления регрессии —
<http://www.machinelearning.ru/wiki/images/a/aa/Voron-ML-Regression.pdf>